



ÉCOLE NATIONALE SUPÉRIEURE
D'INFORMATIQUE ET D'ANALYSE DES SYSTÈMES
- RABAT

TESTS A/B

Scouting Data-Driven

Élèves :

ILYAS BOUSSEMID
MOHAMED EL MOUKH

Prof :

PR. TABII YOUNES

Année Universitaire 2025-2026

1 Cadrage Métier, Hypothèses et Objectifs

1.1 Objectif Stratégique

L'objectif de ce protocole est de valider scientifiquement l'efficacité et la supériorité économique de notre plateforme de recrutement *Data-Driven* (Dashboard IA développé en Phase 5) par rapport à la méthodologie de scouting traditionnelle basée sur l'intuition et l'observation humaine non assistée.

1.2 Formulation des Hypothèses Statistiques

Afin de valider le déploiement à grande échelle de l'algorithme de Machine Learning (Random Forest / Gradient Boosting), nous définissons deux hypothèses strictes :

- **Hypothèse Nulle (H_0)** : Le taux de réussite des recrues identifiées via l'outil IA est inférieur ou égal à celui de la méthode traditionnelle.
- **Hypothèse Alternative (H_1)** : L'utilisation du Dashboard IA augmente de manière significative le taux de réussite des transferts et optimise l'actif financier du club (avec un niveau de confiance $\alpha = 5\%$).

1.3 Indicateurs Clés de Performance (KPIs)

Pour mesurer l'impact réel de l'expérience, trois métriques de succès complémentaires sont suivies sur une période de validation de 6 à 12 mois :

1. **Taux de Réussite Sportive (TRS)** : Pourcentage de joueurs recrutés atteignant les objectifs fixés par la direction (Temps de jeu effectif $> 60\%$ et ratio de buts/passes décisives conforme aux prédictions).
2. **Valorisation de l'Actif (ΔV)** : Évolution en pourcentage de la valeur marchande du joueur sur la plateforme *Transfermarkt* entre le jour de sa signature et la fin de la saison.
3. **Retour sur Investissement Spécifique (ROI)** : Ratio entre la valeur de revente future (ou estimation marché) et le coût d'acquisition initial (limité par notre enveloppe budgétaire de 12 M€).

2 Échantillonnage, Exécution et Cadre Mathématique

2.1 Stratégie d'Échantillonnage (Le Split)

L'ensemble du réseau mondial des recruteurs de la cellule de scouting est scindé de manière aléatoire et équitable en deux groupes distincts à l'aide d'une méthode de répartition stratifiée par zone géographique :

- **Groupe A (Groupe de Contrôle - Humain)** : 50% des recruteurs opèrent selon le flux classique. Ils s'appuient sur les réseaux d'agents, le visionnage de vidéos à la demande et l'instinct pour soumettre leurs recommandations d'attaquants.
- **Groupe B (Groupe Variante - IA)** : 50% des recruteurs intègrent notre outil Streamlit. Ils utilisent les filtres prédictifs et les graphiques radars pour générer une *Short-list* de pépites sous-évaluées avant d'entamer l'audit terrain.

2.2 Dimensionnement et Puissance Statistique

Le test est déployé sur l'intégralité de la fenêtre des transferts (Mercato d'été et d'hiver). Pour garantir la puissance statistique du test ($1 - \beta = 80\%$) et détecter une amélioration minimale de 15% du taux de réussite, l'échantillon doit analyser un minimum de 150 profils de joueurs filtrés par groupe.

2.3 Modèle de Validation Mathématique

À l'échéance du protocole, les proportions de réussite (p_A et p_B) collectées seront comparées via un **Test de Chi-Deux (χ^2) d'indépendance** (ou un test Z de comparaison de deux proportions).

La statistique de test est modélisée par l'équation suivante :

$$Z = \frac{(\hat{p}_B - \hat{p}_A)}{\sqrt{\hat{p}(1 - \hat{p}) \left(\frac{1}{n_A} + \frac{1}{n_B} \right)}} \quad (1)$$

Où $\hat{p}$ represents la proportion globale de réussite combinée.

2.4 Critère d'Adoption du Système

Le club abandonnera définitivement l'ancienne méthode pour migrer vers la solution *Data-Driven* si et seulement si la valeur de probabilité calculée (**P-Value**) vérifie :

$$\text{P-Value} < 0.05 \quad (2)$$

Cette condition atteste que l'écart de performance en faveur de l'IA est mathématiquement robuste et n'est pas le fruit du hasard.